תרגיל בית 1 - למידה חישובית | יונתן ששון

1. Let $x \in \mathbb{R}^d$, and $f(x) = \|x\|_2^2 = x^\top x$. Compute the gradient $\nabla f(x)$ (gradient of the ℓ_2 norm).

קודם כל ארשום את $x^T x$ בצורה כזו: $f(x) = \sum_{i=1}^{d} x_i^2$

עכשיו אעבור לנגזרה ואעשה נגזרת ע״י כך שאקח רכיב ספציפי אחד למשל x_k.
ובעצם כל הרכיבים האחרים הנגזרת שלהם תהיה 0 כי הם מתנהגים כקבועים.
לכן הנגזרת החלקית של $\frac{\partial f}{\partial x_k}$ תהיה $2x_k$.

ולכן אם נעשה נגזרת לכלל הרכיבים נקבל: $\begin{bmatrix} 2x_1 \\ 2x_2 \\ \vdots \\ 2x_d \end{bmatrix}$ שזה בעצם $2\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$

וזה בעצם פעמיים הוקטור המקורי x

לכן: $\boxed{\nabla_x f(x) = 2x} \in \mathbb{R}^d$

2. Let $f(x) = A^\top x \in \mathbb{R}^n$, for $A \in \mathbb{R}^{d\times n}$. Compute the Jacobian of f with respect to x (Jacobian of a linear map).

קודם כל A מוגדרת בגודל $d\times n$ לכן אם נשחלף אותה (T) נקבל $n\times d$.

ואם x בגודל $d\times 1$ נקבל וקטור: $\underset{n\times d}{A^T}\,\underset{d\times 1}{x} = \underset{n\times 1}{?}$.

נבחר רכיב כללי של הפלט: $f_j = (A^T x)_j = \sum_{k=1}^{d} (A^T)_{jk} x_k = \sum_{k=1}^{d} A_{kj} x_k$

נגזור את f_j לפי x_i. רק האיבר $k=i$ בסכום תלוי ב-x_i ושאר האיברים קבועים.

$\frac{\partial f_j}{\partial x_i} = A_{ij}$. לפי ההגדרה בתרגול, האיבר (i,j) של היעקוביאן
הוא $\frac{\partial f_j}{\partial x_i} = A_{ij}$,

כלומר האיבר במקום ה-(i,j) ביעקוביאן שווה ל-A_{ij} כלומר האיבר ה-(i,j)
במטריצה A וזה מתקיים לכל שורה ועמודה לכן היעקוביאן שווה ל-A $\boxed{\frac{\partial f}{\partial x} = A} \in \mathbb{R}^{d\times n}$.

3. Let $g(x) = A^\top x \in \mathbb{R}^n$ and $f(y) = \|y\|_2^2$. Compute the gradient of $f(g(x))$ with respect to x (hint: use the chain rule).

אז לפי כלל השרשרת, הגרדיאנט של פונקציה מורכבת מחושב ע״י הכפלת מטריצת היעקוביאן של הפונקציה הפנימית בגרדיאנט של הפונ׳ החיצונית.

והנוסחה היא: $\nabla_x f(g(x)) = \frac{\partial g}{\partial x} \nabla_y f(y)$

מטריצת היעקוביאן $\frac{\partial g}{\partial x}$ היא בגודל $d \times n$ והגרדיאנט $\nabla_y f(y)$ בגודל $n \times 1$

לכן נקבל: $\frac{\partial g}{\partial x} \cdot \nabla_y f(y) = ?$ נציב מהתוצאות שיצאו בשאלות

הקודמות: $\boxed{\overset{d\times n}{A} \cdot \overset{n\times 1}{2y} = \overset{d\times 1}{2AA^T x} = \nabla_x f(g(x))} \in \mathbb{R}^d$

$\frac{\partial g}{\partial x} = A$, $\nabla_y f(y) = 2y$ $\quad y = A^T x$

משאלה 2. משאלה 1

(בדיוק הרעיון של backprop ששומרים חישובים)

4. Let $g(A) = A^\top x \in \mathbb{R}^n$ and $f(y) = \|y\|_2^2$. Compute the gradient of $f(g(A))$ with respect to A.

הגרדיאנט $\nabla_A f$ עם מימדים $d \times n$ והאיבר (i,j) שלו הוא $\frac{\partial f}{\partial A_{ij}}$.

קודם נסמן $y = A^T x$ וכמו מסעיף 1 שחישבנו: נקבל ש: $\frac{\partial f}{\partial y_k} = 2y_k$.

כמו תמיד נחזור מהו הרכיב הכללי: $y_k = \sum_{l=1}^{d} A_{lk} x_l$ והאיבר A_{ij} משפיע

רק ב- y_j ולכן: $\frac{\partial y_k}{\partial A_{ij}} = \begin{cases} x_i, & k=j \\ 0, & k \neq j \end{cases} = x_i \cdot 1[k=j]$

ואז לפי כלל השרשרת:

$$\frac{\partial f}{\partial A_{ij}} = \sum_{k=1}^{n} \frac{\partial f}{\partial y_k} \cdot \frac{\partial y_k}{\partial A_{ij}} = \sum_{k=1}^{n} 2y_k x_i \cdot 1[k=j] = 2x_i y_j$$

והמטריצה שהאיבר (i,j) שלה הוא $x_i y_j$ היא המכפלה החיצונית xy^T

ולכן $\boxed{\nabla_A f(g(A)) = 2xy^T = 2xx^T A} \in \mathbb{R}^{d\times n}$

(אם נבדוק את המימדים: $(d\times 1)(1\times d)(d\times n)$ אכן נקבל $d\times n$)

B (50 pts)

Figure [1] portrays a basic neural network architecture schema with weights, biases, activation functions, and loss components. The loss is defined as:

$$\text{Loss} = -y \log \hat{y} - (1-y)\log(1-\hat{y})$$

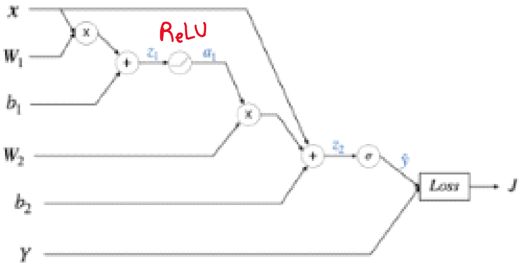

Figure 1: Neural architecture example

מהשרטוט רואים ש-x ו-W_1 נכנסים לכפל ואז התוצאה שלהם מתחברת עם b_1

לכן $z_1 = W_1 \cdot x + b_1$. ואז יש לנו ReLU ← $a_1 = \text{ReLU}(z_1) = \max(0, z_1)$

לאחר מכן a_1, W_2 נכנסים לכפל והתוצאה נכנסת לחיבור עם x ו-b_2 ולכן:

$z_2 = W_2 \cdot a_1 + b_2 + x$ ואז יש לנו $\hat{y} = \sigma(z_2) = \frac{1}{1+e^{-z_2}}$

שזה בעצם הסתברות בין 0-1.

ו-$\hat{y}$ נכנס ל-Loss והפלט הוא: $J = -y \log \hat{y} - (1-y)\log(1-\hat{y})$.

כנתון.

1. Express $\hat{y}$ as a function of x, W_1, b_1, W_2, b_2.

אז עכשיו נתחיל להציב עד שנגיע לנתונים:

$$\hat{y} = \sigma(z_2) = \frac{1}{1+e^{-z_2}} \underset{\substack{\text{נציב}\\ z_2}}{=} \frac{1}{1+e^{-[(W_2 \cdot a_1) + b_2 + x]}}$$

נציב את a_1:

$$\hat{y} = \frac{1}{1+e^{-[W_2 \cdot \max(0, z_1) + b_2 + x]}}$$

נציב את z_1:

$$\boxed{\hat{y} = \frac{1}{1+e^{-[W_2 \cdot \max(0, W_1 \cdot x + b_1) + b_2 + x]}}}$$

2. Compute the gradients $\frac{\partial J}{\partial W_2}$ and $\frac{\partial J}{\partial b_2}$.

$$J=-y\log\hat{y}-(1-y)\log(1-\hat{y})$$

נצטרך לחשב:

$$\frac{\partial J}{\partial W_2}=\frac{\partial J}{\partial \hat{y}}\cdot\frac{\partial \hat{y}}{\partial z_2}\cdot\frac{\partial z_2}{\partial W_2}$$

W_2 משפיע על J דרך z_2 ו-z_2 דרך $\hat{y}$, יש לנו כאן בעצם שרשרת של 3 חוליות, אז נכפול 3 נגזרות.

נחשב לפי כלל השרשרת לאורך המסלול בשרטוט, כל חוליה בנפרד ואז נכפיל:
(back prop)

$\frac{\partial J}{\partial \hat{y}}$ ← נגזור את ההפסד לפי $\hat{y}$ (y קבוע) בעזרת $(\log(u))'=\frac{u'}{u}$

באיבר השני: $u=1-\hat{y}$ ולכן $u'=-1$:

$$\frac{\partial J}{\partial \hat{y}}=-y\cdot\frac{1}{\hat{y}}+(1-y)\left(\frac{1}{1-\hat{y}}\right)=\frac{-y(1-\hat{y})+(1-y)\hat{y}}{\hat{y}(1-\hat{y})}=\frac{\hat{y}-y}{\hat{y}(1-\hat{y})}$$

$\frac{\partial \hat{y}}{\partial z_2}$ ← $\hat{y}=\sigma(z_2)$ ונגזרת הסיגמואיד היא $\sigma(1-\sigma)$.

$$\boxed{\begin{aligned}\sigma(z)&=\frac{1}{1+e^{-z}}\\ \sigma'(z)&=\frac{e^{-z}}{(1+e^{-z})^2}\\ &=\underbrace{\frac{1}{1+e^{-z}}}_{\sigma}\cdot\underbrace{\frac{e^{-z}}{1+e^{-z}}}_{(1-\sigma)}\end{aligned}}$$

ומכיוון ש: $\sigma(z_2)=\hat{y}$: $\frac{\partial \hat{y}}{\partial z_2}=\hat{y}(1-\hat{y})$.

נכפיל: (נקרא לזה δ_2)

$$(1\ \frac{\partial J}{\partial \hat{y}}\cdot(2\ \frac{\partial \hat{y}}{\partial z_2}=\frac{\hat{y}-y}{\cancel{\hat{y}(1-\hat{y})}}\cdot\cancel{\hat{y}(1-\hat{y})}=\hat{y}-y=\delta_2$$

עכשיו נחשב את: $\frac{\partial J}{\partial W_2}$. אנחנו יודעים ש: $z_2=W_2a_1+b_2+X$ כלומר:

$$(z_2)_i=\sum_j (W_2)_{ij}(a_1)_j+(b_2)_i+X_i$$

ואז $(W_2)_{ij}$ מופיע בעצם רק באיבר אחד של הסכום והוא מוכפל ב-$(a_1)_j$ ולכן

$$\frac{\partial (z_2)_i}{\partial (W_2)_{ij}}=(a_1)_j$$

לפי כלל השרשרת $\frac{\partial J}{\partial (W_2)_{ij}} = (\delta_2)_i (a_1)_j$ כלומר:

$$\boxed{\frac{\partial J}{\partial W_2} = \delta_2 a_1^T = (\hat{y} - y) a_1^T}$$

עכשיו: $\frac{\partial J}{\partial b_2}$ בעצם b_2 רק מתווסף ל-z_2 ולכן הנגזרת שלו היא 1 (הגרדיאנט עובר כמו שהוא):

$$\boxed{\frac{\partial J}{\partial b_2} = \delta_2 = \hat{y} - y}$$

3. Compute the gradients $\frac{\partial J}{\partial W_1}$, $\frac{\partial J}{\partial b_1}$, and $\frac{\partial J}{\partial x}$.

עכשיו צריך את הגרדיאנטים של השכבה הראשונה, נשים לב שהמסלול מ-W_1 ל-J הוא ארוך יותר:

$$W_1 \to z_1 \to a_1 \to \underbrace{z_2 \to J}_{\substack{\text{חישבנו כבר} \\ \delta_2 = \hat{y} - y}}$$

$$\frac{\partial J}{\partial W_1} = \delta_2 \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial W_1}$$

① נחשב את $\frac{\partial J}{\partial a_1}$: נכתוב את z_2 כרכיב אחרי רכיב ונראה את a_1:

$$(z_2)_i = \sum_j (W_2)_{ij} (a_1)_j + (b_2)_i + x_i$$

תרגיל בית 1 - למידה חישובית | יונתן ששון

$\frac{\partial (z_2)_i}{\partial (a_1)_j} = (W_2)_{ij}$ ‏$(a_1)_j$ מופיע באיבר אחד בסכום והוא מוכפל ב- $(W_2)_{ij}$

עכשיו כלל השרשרת, הנוירון $(a_1)_j$ משפיע על כל הרכיבים $(z_2)_i$ ולכן נסכום על כל ה-i.

$$\frac{\partial J}{\partial (a_1)_j} = \sum_i (\delta_2)_i (W_2)_{ij}.$$

נרשום את זה בכתיב מטריציוני:

$$\frac{\partial J}{\partial a_1} = W_2^T \delta_2.$$

כעת השלב ה-2 ReLU:

$a_1 = \max(0, z_1)$ עבור אחדה מ- a_1 ל- z_1.

$$\frac{\partial (a_1)_k}{\partial (z_1)_k} = 1\cdot[(z_1)_k > 0]$$

אינדיקטור.

אם $z_1>0$ אז $a_1 = z_1$ והנגזרת=1

אחרת זה פשוט 0.

נקרא לזה $\delta_1 \rightarrow \frac{\partial J}{\partial z_1} = (W_2^T \delta_2) \odot 1[z_1 > 0]$

כפל של איבר איבר.

בעצם כל נוירון עובר ReLU משלו
ולכן כל רכיב של האות מוכפל בשיפוע של
הנוירון שלו, נוירון דלוק מעביר את האות
ונוירון "כבוי" חוסם אותו כלומר 0.

ועכשיו שלב שלב: $\frac{\partial J}{\partial W_1}, \frac{\partial J}{\partial b_1}$

$z_1 = W_1X + b_1$ וזה כמו המבנה של $z_2 = W_2a_1 + b_2$ מהסעיף השני, זה בעצם משקל כפול קלט+הטיה לכן אפשר להשתמש באותו חישוב:

$$\boxed{\frac{\partial J}{\partial W_1} = \delta_1 X^T}$$

(רק שינוי אותיות בהתאם).

וגם $\boxed{\frac{\partial J}{\partial b_1} = \delta_1}$ כי ההטיה רק מתווספת, הנגזרת=1 לכן הגרדיאנט
עובר כמו שהוא)

ועכשיו $\frac{\partial J}{\partial x}$:

x משפיע על J ב-2 דרכים, דרך z_1 ודרך חיבור הדילוג ל-z_2.

אפשר לראות בשרטוט שיוצאים מ-x 2 קווים ולכן נחשב כל אחד והתרומה שלו.

$z_1=W_1x+b_1$, התרומה היא $W_1^T\delta_1$ (אותו חישוב כמו מקודם)

$z_2=\cdots+x$ התרומה היא δ_2 (פשוט מתווסף x ל-z_2 והנגזרת היא 1).

ועכשיו כלל השרשרת

$$\boxed{\frac{\partial J}{\partial x}=W_1^T\delta_1+\delta_2=W_1^T\delta_1+(\hat{y}-y)}$$

4. What intermediate variables do we need to cache in the above calculations?

כיוון, אז ב-backward אנחנו משתמשים בערכים שחישבנו כבר ב-forward
לכן אותם נרצה לשמור בקאש, בזמן ה-forward. (כי אם לא, נצטרך לחשב שוב).

אז עברתי על הנוסחאות הגרדיאנטים מהסעיפים הקודמים ובעצם בדקתי מה כל אחת צריכה מה-forward:

$\delta_2=\hat{y}-y$ צריכה את $\hat{y}$.

$\frac{\partial J}{\partial W_2}=\delta_2 a_1^T$ צריכה את a_1.

δ_1 צריכה את z_1

$\frac{\partial J}{\partial W_1}=\delta_1 X^T$ צריכה את X

לכן נצטרך לשמור את $\hat{y}, a_1, z_1, X$ (ואת y גם).

בזמן שה-backward שומרים את δ_2 ו-δ_1 כי משתמשים בהם אח״כ גם